Projet Big Data

Master 2 SID

Analyse des Matchs de Football des 5 Grandes Ligues Européennes

Rédigé le 15/03/2026, par

TIOUAL Ahmed
EL MAATLA Lotfi

Encadré par

Prof. MINICH Sarah

Table des matières

1 Introduction **2**

2 Sources de données **2**

2.1 Périmètre de l'étude 2

2.2 Collecte et Format 2

2.3 Description des attributs 3

3 Modélisation multidimensionnelle **3**

3.1 Schéma en étoile 3

3.2 Table de faits 3

3.3 Tables de dimensions 4

3.3.1 Dimension Équipe 4

3.3.2 Dimension Compétition 5

3.3.3 Dimension Date 5

3.3.4 Dimension Arbitre 5

3.4 Avantages du modèle 5

4 Processus ETL **6**

4.1 Extraction des données 6

4.2 Transformation des données 6

4.3 Chargement dans l'entrepôt de données 7

4.4 Flux ETL dans Talend 7

5 Entrepôt de données **9**

5.1 Structure de l'entrepôt 9

5.2 Table de faits 10

5.3 Tables de dimensions 11

5.4 Avantages de l'entrepôt de données 12

6 Visualisation et tableaux de bord **13**

6.1 Dashboard 1 : League Overview 13

6.2 Dashboard 2 : Team Performance 14

6.3 Dashboard 3 : Match Analysis 15

7 Conclusion **16**

1 Introduction

L'analyse des données sportives est devenue un levier stratégique dans le football moderne. Les clubs et les analystes exploitent désormais ces informations pour décrypter les performances, anticiper les résultats et identifier des tendances structurelles sur le long terme.

Dans le cadre de ce projet de Big Data et de Business Intelligence, l'objectif est de concevoir un système décisionnel complet permettant d'explorer les résultats des principales ligues européennes sur une période de 24 ans (**2000 à 2024**). Ce projet vise à transformer des données historiques brutes en indicateurs visuels pertinents pour l'analyse sportive.

Afin de répondre à ces enjeux, nous avons structuré notre démarche autour d'une architecture décisionnelle classique :

- **Collecte et ingestion** : Récupération automatisée des données sources.
- **Modélisation** : Conception d'un schéma multidimensionnel (étoile) adapté au décisionnel.
- **Intégration (ETL)** : Nettoyage et chargement des données via Talend vers PostgreSQL.
- **Restitution** : Création de tableaux de bord interactifs sous Power BI.

Ce rapport détaille chaque étape de cette chaîne de valeur, des choix techniques de stockage jusqu'aux analyses finales.

2 Sources de données

La fiabilité du système décisionnel repose sur la qualité des sources primaires. Pour ce projet, les données ont été extraites du site *football-data.co.uk*, une référence publique pour les statistiques historiques du football européen.

2.1 Périmètre de l'étude

Le jeu de données agrège les résultats des cinq championnats majeurs, offrant ainsi une vision comparative des dynamiques européennes :

- **Angleterre** (Premier League), **Espagne** (La Liga), **Italie** (Serie A), **Allemagne** (Bundesliga) et **France** (Ligue 1).

2.2 Collecte et Format

Les données sont initialement fournies sous forme de fichiers **CSV** par saison. Nous avons mis en place un processus de **scraping** permettant l'automatisation du télécharge-

ment de ces fichiers. Ce mode opératoire garantit la reproductibilité de la collecte pour les saisons futures.

2.3 Description des attributs

Chaque enregistrement représente un match unique. Les fichiers bruts contiennent des informations cruciales qui servent de base à nos indicateurs :

- **Informations temporelles** : Date précise de la rencontre.
- **Acteurs** : Équipes (domicile/extérieur) et arbitre désigné.
- **Scores** : Résultats à la mi-temps et score final.
- **Résultat technique** : Issue du match (Victoire domicile, Nul, Victoire extérieur).

Ces données brutes subissent ensuite une phase de prétraitement pour corriger les éventuelles incohérences avant d'alimenter l'entrepôt de données.

3 Modélisation multidimensionnelle

Afin de faciliter l'analyse décisionnelle des données de matchs de football, nous avons adopté une approche de modélisation multidimensionnelle basée sur un **schéma en étoile (Star Schema)**. Ce type de modélisation est largement utilisé dans les entrepôts de données car il permet d'optimiser les requêtes analytiques et de simplifier l'exploration des données.

Le schéma en étoile se compose d'une **table de faits centrale** contenant les mesures quantitatives, entourée de plusieurs **tables de dimensions** décrivant le contexte des observations.

3.1 Schéma en étoile

La Figure 1 présente la structure du modèle multidimensionnel utilisé dans ce projet.

Dans ce modèle, la table de faits *Fact_Match* est reliée à plusieurs dimensions permettant d'analyser les données selon différents axes tels que les équipes, la compétition, la date ou l'arbitre.

3.2 Table de faits

La table de faits **Fact_Match** contient les mesures principales associées à chaque match. Chaque enregistrement représente une rencontre entre deux équipes dans une compétition donnée.

Les principales mesures stockées dans cette table sont :

- le nombre de buts marqués par l'équipe à domicile (*fulltime_home*) ;
- le nombre de buts marqués par l'équipe à l'extérieur (*fulltime_away*) ;

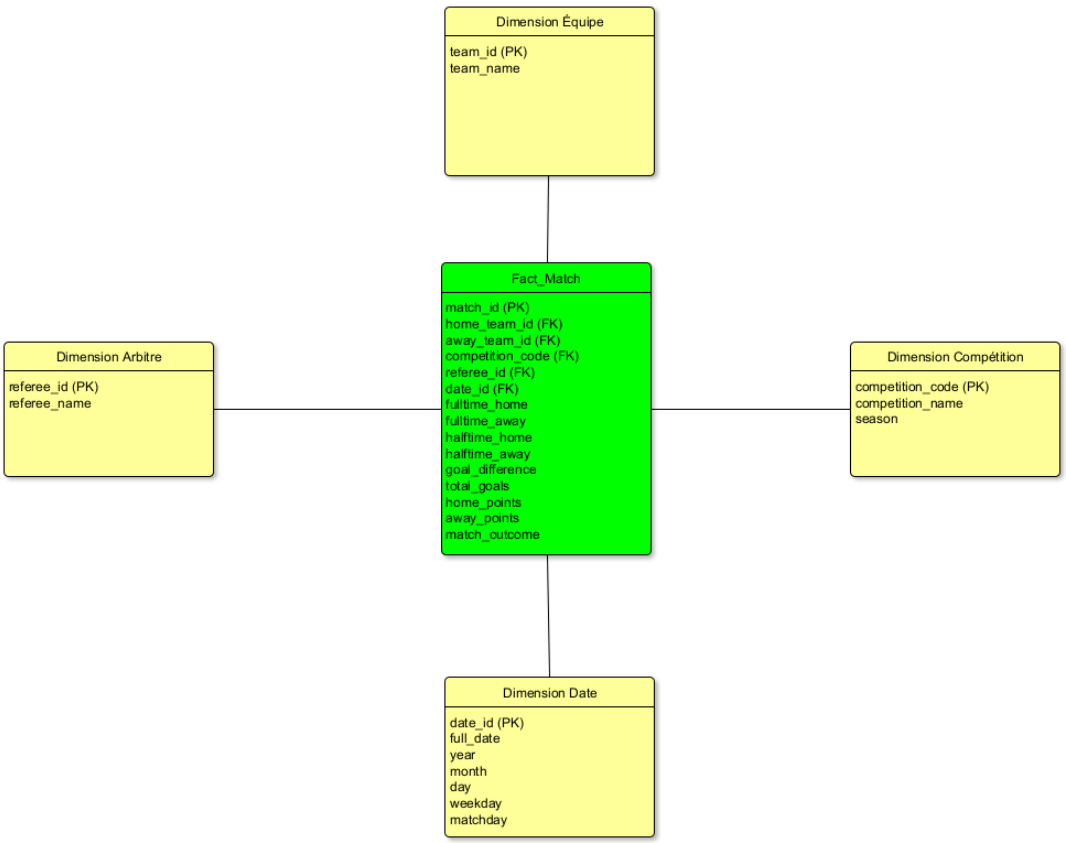

FIGURE 1 – Schéma en étoile de l'entrepôt de données des matchs de football

- le nombre total de buts du match (*total_goals*) ;
- la différence de buts (*goal_difference*) ;
- les points attribués aux équipes (*home_points* et *away_points*) ;
- le résultat final du match (*match_outcome*).

Cette table contient également plusieurs clés étrangères permettant de relier les mesures aux différentes dimensions analytiques.

3.3 Tables de dimensions

Plusieurs tables de dimensions ont été créées afin de fournir le contexte nécessaire à l'analyse des matchs.

3.3.1 Dimension Équipe

La dimension **Dim_Team** contient les informations relatives aux équipes participant aux différentes compétitions.

- **team_id** : identifiant unique de l'équipe
- **team_name** : nom de l'équipe
- **city** : ville du club

- **country** : pays du club

Cette dimension est utilisée deux fois dans la table de faits pour représenter l'équipe à domicile et l'équipe à l'extérieur.

3.3.2 Dimension Compétition

La dimension **Dim_Competition** décrit les différentes compétitions étudiées dans le projet.

- **competition_code** : identifiant de la compétition
- **competition_name** : nom de la compétition
- **season** : saison sportive

Cette dimension permet d'analyser les performances par championnat et par saison.

3.3.3 Dimension Date

La dimension **Dim_Date** permet d'effectuer des analyses temporelles.

- **date_id** : identifiant de la date
- **full_date** : date complète du match
- **year** : année
- **month** : mois
- **day** : jour
- **weekday** : jour de la semaine

Grâce à cette dimension, il est possible d'étudier l'évolution des performances et du nombre de buts au fil du temps.

3.3.4 Dimension Arbitre

La dimension **Dim_Referee** contient les informations sur les arbitres ayant officié les matchs.

- **referee_id** : identifiant de l'arbitre
- **referee_name** : nom de l'arbitre

Cette dimension permet notamment d'analyser le nombre de matchs arbitrés ainsi que certaines tendances liées aux rencontres dirigées par différents arbitres.

3.4 Avantages du modèle

Ce modèle multidimensionnel permet d'analyser les matchs de football selon plusieurs perspectives :

- l'évolution des buts marqués au cours du temps ;
- la performance des équipes dans différentes compétitions ;
- la comparaison entre les matchs à domicile et à l'extérieur ;

- l'analyse des statistiques par arbitre ou par championnat.

Il constitue ainsi une base solide pour l'intégration des données dans l'entrepôt de données et pour la création des tableaux de bord analytiques présentés dans la suite du rapport.

4 Processus ETL

Afin d'intégrer les données collectées dans l'entrepôt de données, nous avons mis en place un processus **ETL (Extract, Transform, Load)**. Ce processus permet d'extraire les données brutes, de les transformer afin d'assurer leur cohérence et leur qualité, puis de les charger dans la structure multidimensionnelle définie précédemment.

Pour implémenter ce pipeline de données, nous avons utilisé l'outil **Talend Open Studio**, qui permet d'automatiser les flux et de gérer efficacement l'intégration vers notre base PostgreSQL.

4.1 Extraction des données

Contrairement à une approche par fichiers séparés, la première étape du processus repose sur l'exploitation d'un **fichier CSV unique**, généré lors de la phase de scraping. Ce fichier consolide l'ensemble des matchs de toutes les ligues et saisons étudiées (2000-2024).

L'importation dans Talend s'effectue via le composant `tFileInputDelimited`. Ce fichier source contient toutes les informations nécessaires à l'alimentation du modèle, notamment :

- la date du match ;
- les équipes à domicile et à l'extérieur ;
- les scores à la mi-temps et à la fin du match ;
- l'arbitre du match ;
- le résultat final de la rencontre.

L'utilisation d'un fichier consolidé dès l'extraction simplifie le pipeline Talend en évitant l'usage de boucles complexes d'itération sur plusieurs répertoires.

4.2 Transformation des données

Après l'extraction, les données subissent une série de transformations visant à garantir leur intégrité et leur adéquation avec le modèle multidimensionnel cible. Cette étape est cruciale pour transformer les données brutes du fichier CSV consolidé en informations analytiques exploitables.

L'implémentation de cette logique repose sur l'utilisation combinée de trois composants clés dans Talend :

- **Conversion et typage (`tConvertType`)** : Ce composant est utilisé pour assurer la correspondance entre les formats de données du fichier source (généralement interprétés comme des chaînes de caractères par défaut) et les types de données attendus dans PostgreSQL. Nous l'utilisons notamment pour convertir les scores en entiers et les colonnes temporelles en formats *Date*, évitant ainsi tout rejet lors du chargement.
- **Gestion de l'unicité (`tUniqRow`)** : Essentiel pour la construction des tables de dimensions, ce composant permet de filtrer les données et d'éliminer les doublons. Il garantit que chaque équipe, chaque arbitre ou chaque compétition n'apparaît qu'une seule fois dans les tables de référence, assurant ainsi l'intégrité référentielle de l'entrepôt.
- **Logique métier et mapping (`tMap`)** : Véritable cœur du processus, ce composant centralise les transformations complexes :
  - **Standardisation** : Uniformisation des noms d'équipes et des codes de ligues.
  - **Règles de gestion** : Attribution automatique des points (3 pour une victoire, 1 pour un nul, 0 pour une défaite).
  - **Jointures (Lookups)** : Récupération des clés primaires des dimensions pour les injecter en tant que clés étrangères dans la table de faits.

Ces composants permettent d'obtenir un flux de données propre, typé et parfaitement structuré avant son insertion finale dans la base de données.

4.3 Chargement dans l'entrepôt de données

La dernière étape consiste à charger les données dans **PostgreSQL** selon une logique de schéma en étoile. Le chargement est séquencé pour respecter l'intégrité des données :

- Envoi des données uniques vers les tables de dimensions (*Dim_ Team*, *Dim_ Competition*, etc.).
- Insertion des mesures dans la table de faits (*Fact_ Match*) après récupération des clés étrangères.

4.4 Flux ETL dans Talend

L'implémentation a été structurée en deux jobs principaux orchestrés par un job maître pour garantir que les dimensions existent avant l'insertion des faits.

1. Alimentation des dimensions

La Figure 2 montre comment le fichier CSV unique est lu, puis filtré par `tUniqRow` pour extraire les valeurs distinctes nécessaires aux dimensions *Competition*, *Referee*, *Team* et *Date*.

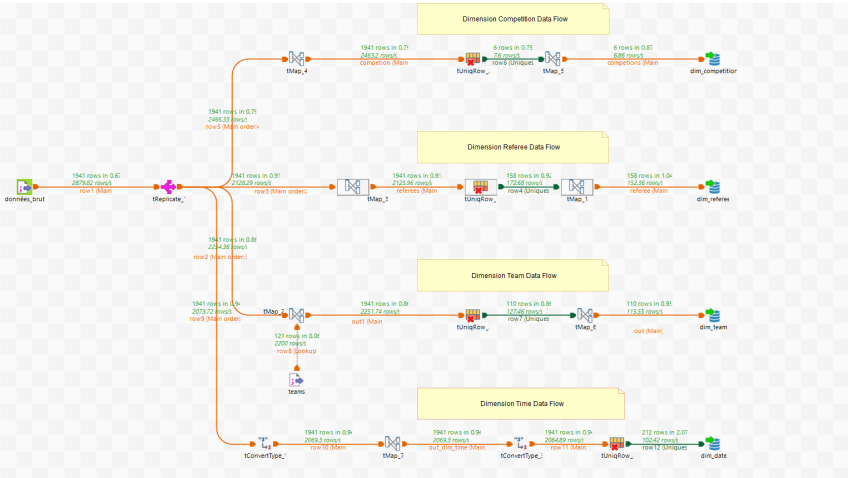

FIGURE 2 – Flux ETL d'alimentation des dimensions (DIM_JOB)

2. Alimentation de la table de faits

Une fois les dimensions prêtes, le flux dédié à la table de faits entre en jeu (Figure 3). Ce job traite le fichier source consolidé afin d'assurer la cohérence du modèle final.

L'étape centrale consiste à réaliser un contrôle référentiel via le composant `tMap` en effectuant des recherches (*lookups*) sur les tables de dimensions chargées dans PostgreSQL. Cette opération permet de récupérer les clés étrangères correspondantes pour chaque enregistrement avant de procéder à l'insertion finale dans la table *Fact_Match*.

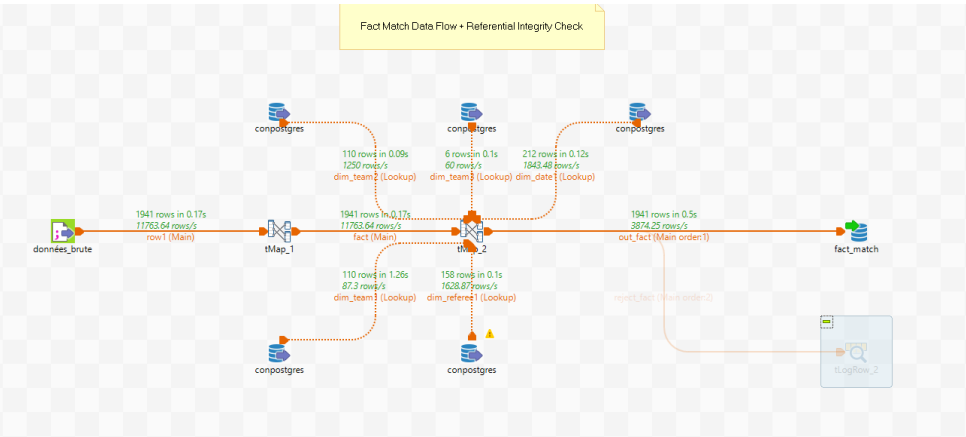

FIGURE 3 – Flux ETL d'alimentation de la table de faits (FACT_JOB)

3. Orchestration globale (Job Maître)

Le job maître (Figure 4) assure la sécurité du processus : le chargement des faits ne démarre que si l'alimentation des dimensions s'est terminée avec succès.

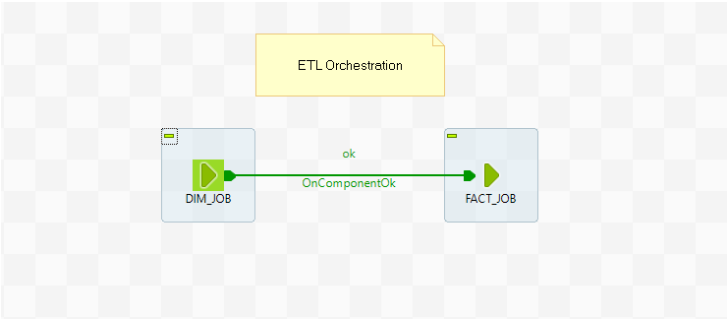

FIGURE 4 – Orchestration des flux : DIM_JOB suivi de FACT_JOB

5 Entrepôt de données

Après la phase de modélisation multidimensionnelle et la mise en place du processus ETL, les données transformées ont été stockées dans un **entrepôt de données** afin de permettre leur exploitation analytique. L'entrepôt de données constitue la base centrale du système décisionnel et permet de consolider l'ensemble des informations issues des différentes sources.

Dans ce projet, l'entrepôt de données a été implémenté à l'aide du système de gestion de base de données relationnelle **PostgreSQL**. Ce choix repose sur sa robustesse, sa capacité à gérer de grands volumes de données et sa compatibilité avec les outils d'intégration de données et de visualisation utilisés dans ce projet.

5.1 Structure de l'entrepôt

L'entrepôt de données est structuré selon un modèle multidimensionnel de type **schéma en étoile**. Cette structure permet d'optimiser les requêtes analytiques et de faciliter la création d'indicateurs et de tableaux de bord.

L'entrepôt est composé des tables suivantes :

- **Fact_Match** : table de faits contenant les mesures principales associées aux matchs.
- **Dim_Team** : dimension contenant les informations sur les équipes.
- **Dim_Competition** : dimension décrivant les compétitions et les saisons.
- **Dim_Date** : dimension temporelle permettant les analyses par date.
- **Dim_Referee** : dimension contenant les informations sur les arbitres.

Chaque table de dimension possède une clé primaire qui est utilisée pour former la clé composite de substitution dans la table de faits *Fact_Match*. Cette organisation permet de relier efficacement les mesures aux différents axes d'analyse.

5.2 Table de faits

La table **Fact_Match** représente le cœur de l'entrepôt de données. Chaque enregistrement correspond à un match joué dans une compétition donnée.

Cette table contient notamment les attributs suivants :

- **home_team_id** et **away_team_id** : clés de substitution des équipes
- **competition_code** : clé de substitution de la compétition
- **referee_id** : clé de substitution de l'arbitre
- **date_id** : clé de substitution de la date du match
- **fulltime_home** et **fulltime_away** : nombre de buts marqués par chaque équipe
- **total_goals** : nombre total de buts dans le match
- **goal_difference** : différence de buts entre les deux équipes
- **home_points** et **away_points** : points attribués aux équipes
- **match_outcome** : résultat du match (victoire domicile, victoire extérieur ou match nul)

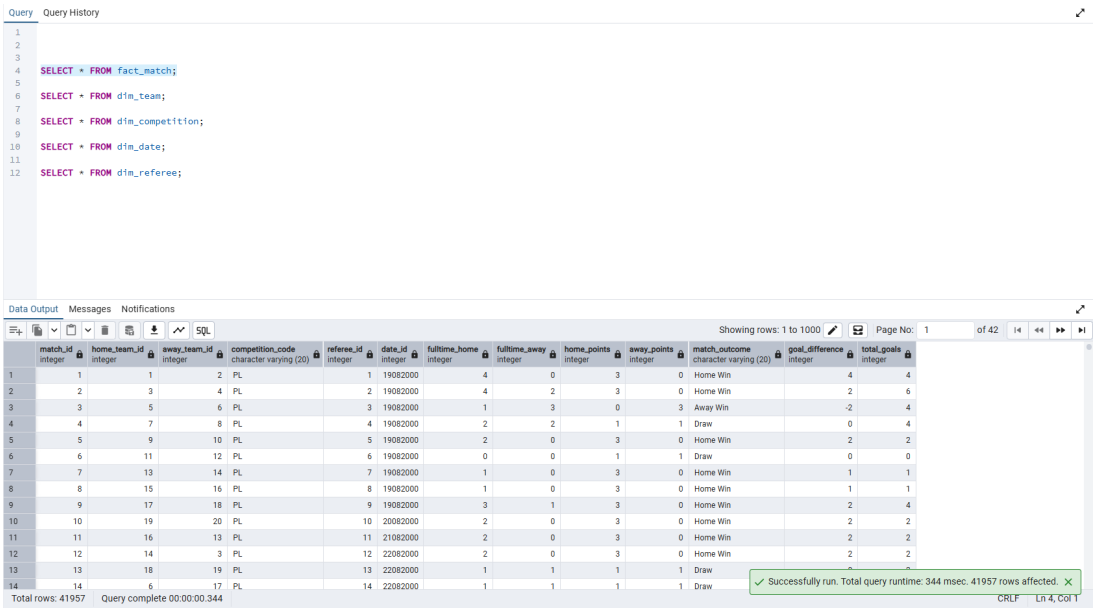

FIGURE 5 – Capture des données de la table Fact_Match

Ces mesures permettent de calculer différents indicateurs analytiques tels que le nombre total de buts, les performances des équipes ou la distribution des résultats.

5.3 Tables de dimensions

Les tables de dimensions apportent le contexte nécessaire à l'analyse des données.

Dim_Team contient les informations sur les équipes telles que le nom du club, la ville et le pays. Cette dimension permet d'analyser les performances par équipe ou par pays.

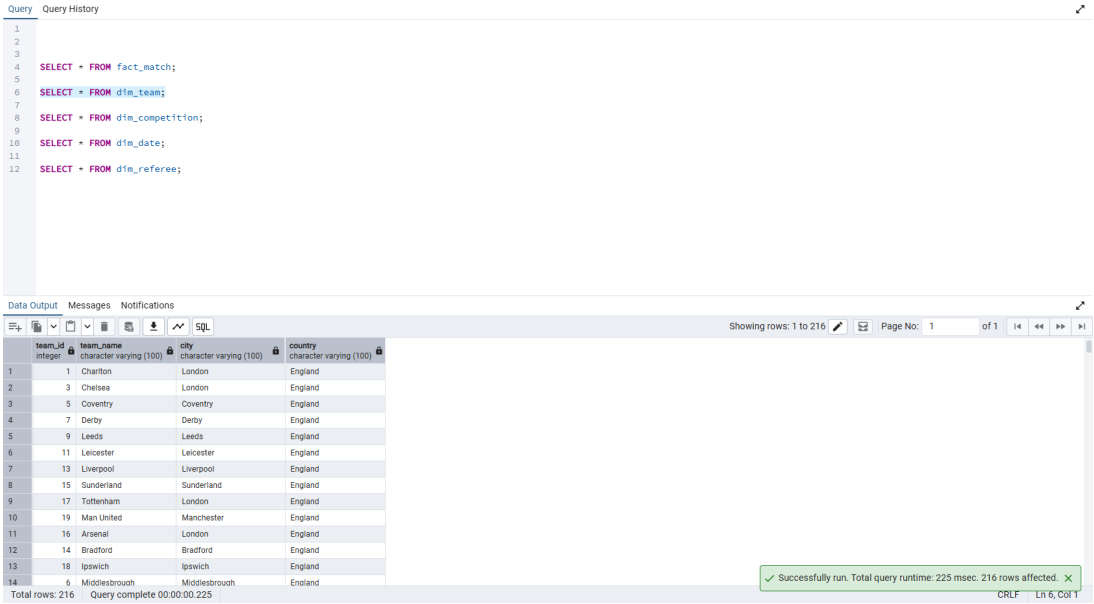

```
SELECT * FROM fact_match;

SELECT * FROM dim_team;

SELECT * FROM dim_competition;

SELECT * FROM dim_date;

SELECT * FROM dim_referee;
```

	team_id integer	team_name character varying (100)	city character varying (100)	country character varying (100)
1	1	Charlton	London	England
2	3	Chelsea	London	England
3	5	Coventry	Coventry	England
4	7	Derby	Derby	England
5	9	Leeds	Leeds	England
6	11	Leicester	Leicester	England
7	13	Liverpool	Liverpool	England
8	15	Sunderland	Sunderland	England
9	17	Tottenham	London	England
10	19	Man United	Manchester	England
11	16	Arsenal	London	England
12	14	Bradford	Bradford	England
13	18	Ipswich	Ipswich	England
14	6	Middlesbrough	Middlesbrough	England

Total rows: 216 Query complete 00:00:00.225

Successfully run. Total query runtime: 225 msec. 216 rows affected.

FIGURE 6 – Capture des données de la table Dim_Team

Dim_Competition regroupe les informations relatives aux compétitions et aux saisons. Elle permet de comparer les performances entre les différents championnats.

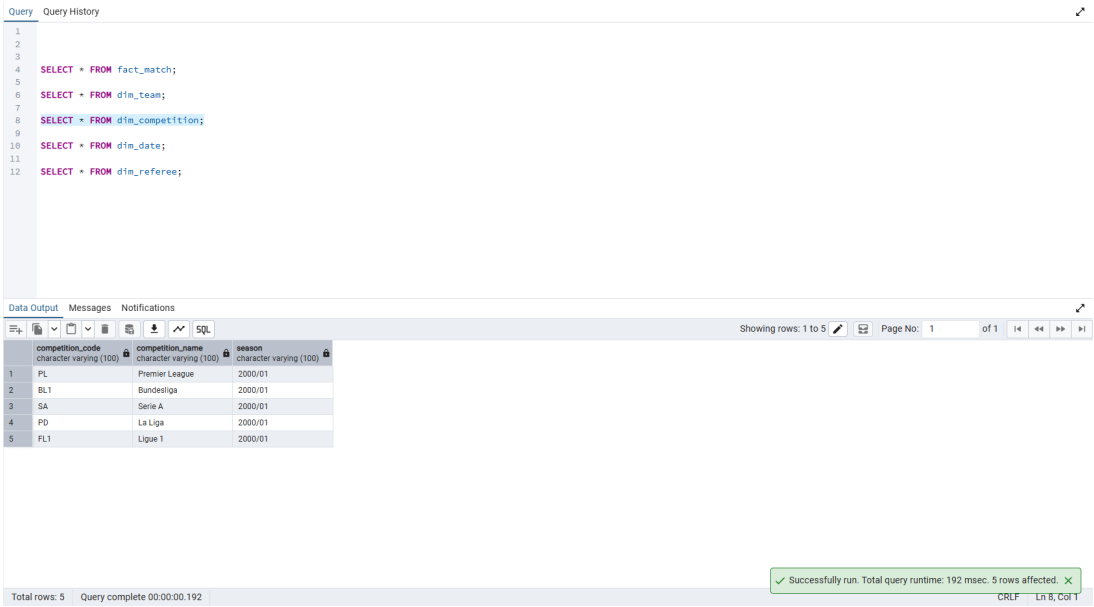

```
SELECT * FROM fact_match;

SELECT * FROM dim_team;

SELECT * FROM dim_competition;

SELECT * FROM dim_date;

SELECT * FROM dim_referee;
```

	competition_code character varying (100)	competition_name character varying (100)	season character varying (100)
1	PL	Premier League	2000/01
2	BL1	Bundesliga	2000/01
3	SA	Serie A	2000/01
4	PD	La Liga	2000/01
5	FL1	Ligue 1	2000/01

Total rows: 5 Query complete 00:00:00.192

Successfully run. Total query runtime: 192 msec. 5 rows affected.

FIGURE 7 – Capture des données de la table Dim_Competition

Dim_Date fournit les informations temporelles nécessaires aux analyses chronologiques, telles que l'année, le mois ou le jour de la semaine.

Query Query History

```sql
SELECT * FROM fact_match;

SELECT * FROM dim_team;

SELECT * FROM dim_competition;

SELECT * FROM dim_date;

SELECT * FROM dim_referee;
```

Data Output Messages Notifications

Showing rows: 1 to 1000 Page No: 1 of 5

	date_id integer	full_date date	year integer	month integer	day integer	weekday character varying (20)
1	19082000	2000-08-...	2000	8	19	Saturday
2	20082000	2000-08-...	2000	8	20	Sunday
3	21082000	2000-08-...	2000	8	21	Monday
4	22082000	2000-08-...	2000	8	22	Tuesday
5	23082000	2000-08-...	2000	8	23	Wednesday
6	26082000	2000-08-...	2000	8	26	Saturday
7	27082000	2000-08-...	2000	8	27	Sunday
8	5092000	2000-09-...	2000	9	5	Tuesday
9	6092000	2000-09-...	2000	9	6	Wednesday
10	9092000	2000-09-...	2000	9	9	Saturday
11	10092000	2000-09-...	2000	9	10	Sunday
12	11092000	2000-09-...	2000	9	11	Monday
13	16092000	2000-09-...	2000	9	16	Saturday
14	17092000	2000-09-...	2000	9	17	Sunday

Successfully run. Total query runtime: 241 msec. 4009 rows affected.

Total rows: 4009 Query complete 00:00:00.241 CRLF Ln 10, Col 1

FIGURE 8 – Capture des données de la table Dim_Date

Dim_Referee contient les informations sur les arbitres ayant dirigé les matchs, permettant ainsi d'étudier certaines statistiques liées à l'arbitrage.

Query Query History

```sql
SELECT * FROM fact_match;

SELECT * FROM dim_team;

SELECT * FROM dim_competition;

SELECT * FROM dim_date;

SELECT * FROM dim_referee;
```

Data Output Messages Notifications

Showing rows: 1 to 263 Page No: 1 of 1

	referee_id integer	referee_name character varying (100)
1	1	Rob Harris
2	2	Graham Barber
3	3	Barry Knight
4	4	Andy D'Urso
5	5	Dermot Gallagher
6	6	Mike Riley
7	7	Paul Durkin
8	8	Steve Dunn
9	9	Alan Wiley
10	10	Steve Lodge
11	11	Graham Poll
12	12	Mark Halsey
13	13	Jeff Winter
14	14	Peter Jones

Successfully run. Total query runtime: 228 msec. 263 rows affected.

Total rows: 263 Query complete 00:00:00.228 CRLF Ln 12, Col 1

FIGURE 9 – Capture des données de la table Dim_Referee

5.4 Avantages de l'entrepôt de données

La mise en place de cet entrepôt de données présente plusieurs avantages pour l'analyse décisionnelle :

- centralisation des données issues de différentes sources ;
- amélioration des performances des requêtes analytiques ;
- simplification de la création d'indicateurs et de tableaux de bord ;
- possibilité d'effectuer des analyses multidimensionnelles selon différents axes (temps, équipe, compétition, arbitre).

Cet entrepôt constitue ainsi la base permettant d'alimenter les tableaux de bord Power BI et de produire les analyses présentées dans la suite de ce rapport.

6 Visualisation et tableaux de bord

Après l'intégration des données dans l'entrepôt de données, l'étape suivante consiste à exploiter ces informations afin de produire des analyses visuelles. Pour cela, nous avons utilisé l'outil **Power BI**, qui permet de créer des tableaux de bord interactifs facilitant l'exploration et l'analyse des données.

Les tableaux de bord développés permettent d'analyser les performances des équipes, les résultats des matchs ainsi que les tendances globales des compétitions. Afin d'améliorer l'interactivité, plusieurs **filtres (slicers)** ont été intégrés dans chaque page :

- Compétition
- Équipe
- Date
- Arbitre

Ces filtres permettent aux utilisateurs d'explorer dynamiquement les données selon différents critères.

6.1 Dashboard 1 : League Overview

Ce tableau de bord offre une vue globale des compétitions et des performances générales des matchs.

KPIs

- **Total Matches** : nombre total de matchs joués dans la période sélectionnée.
- **Total Goals** : nombre total de buts marqués.
- **Average Goals per Match** : moyenne de buts marqués par match.
- **Home Win %** : pourcentage de victoires à domicile.
- **Away Win %** : pourcentage de victoires à l'extérieur.
- **Draw %** : pourcentage de matchs nuls.

Visualisations

- **Match Outcomes Distribution (Pie Chart)** Permet d'observer la répartition des résultats des matchs entre victoires à domicile, victoires à l'extérieur et matchs nuls.

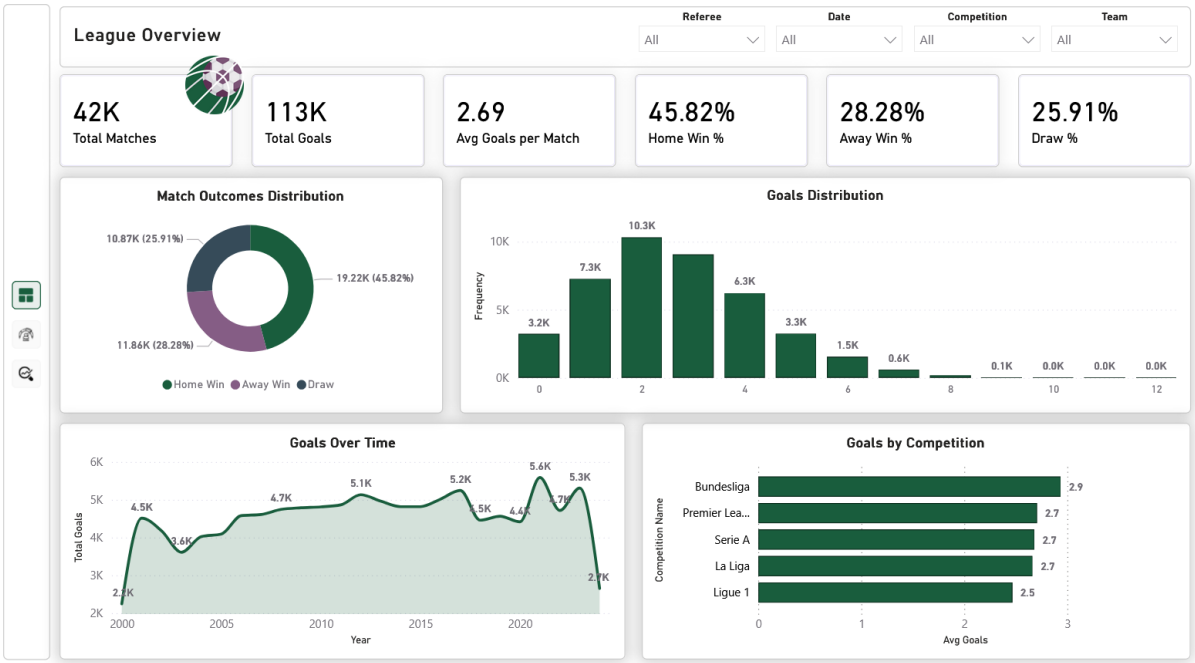

FIGURE 10 – Dashboard League Overview

- **Goals Distribution (Histogram)** Montre la fréquence des matchs selon le nombre total de buts marqués. Ce graphique permet d'identifier si les matchs sont généralement peu ou très prolifiques en buts.
- **Goals Over Time (Line Chart)** Permet d'analyser l'évolution du nombre de buts marqués au fil du temps et d'identifier certaines tendances saisonnières.
- **Goals by Competition (Horizontal Bar Chart)** Compare le nombre total de buts marqués dans les différentes compétitions afin d'identifier les championnats les plus offensifs.

6.2 Dashboard 2 : Team Performance

Ce tableau de bord se concentre sur l'analyse des performances des équipes.

KPIs

- **Total Points** : nombre total de points obtenus par une équipe.
- **Matches Played** : nombre total de matchs disputés.
- **Goals Scored** : nombre total de buts marqués.
- **Goal Difference** : différence entre buts marqués et buts encaissés.

Visualisations

- **Team Ranking (Horizontal Bar Chart)** Classe les équipes selon le nombre total de points obtenus. Ce graphique permet d'identifier rapidement les équipes les plus performantes.
- **Home vs Away Performance (Stacked Bar Chart)** Compare les performances

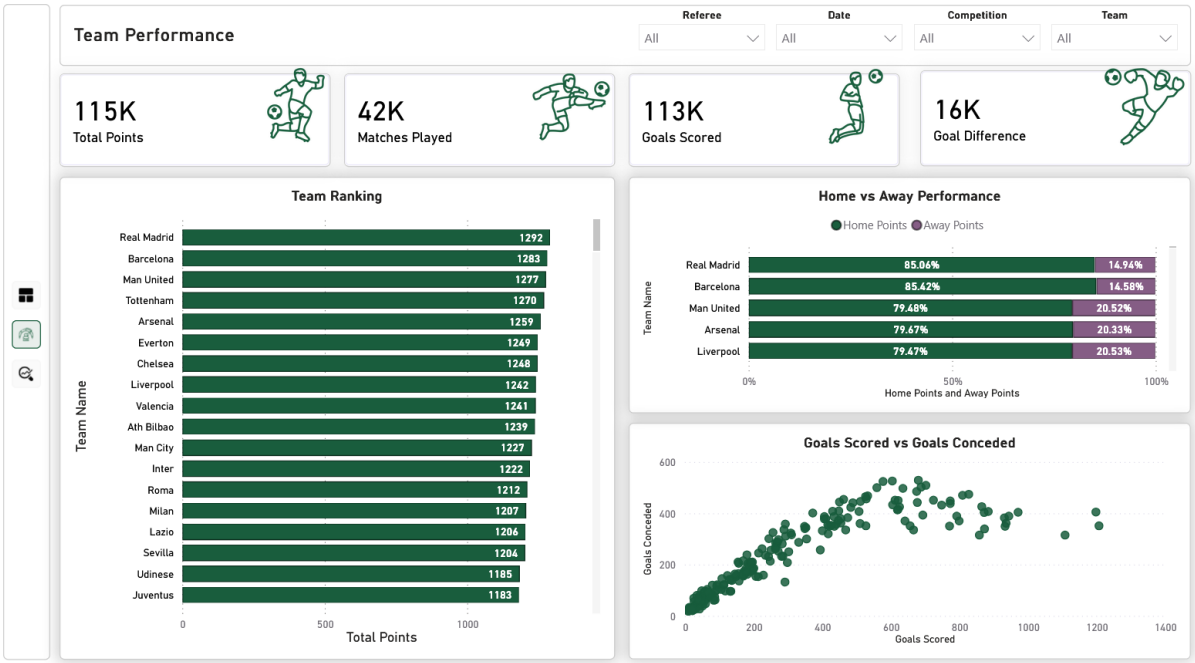

FIGURE 11 – Dashboard Team Performance

d'une équipe à domicile et à l'extérieur afin d'analyser l'impact de l'avantage du terrain.

- **Goals Scored vs Goals Conceded (Scatter Plot)** Permet de comparer la capacité offensive et défensive des équipes. Les équipes situées dans la partie supérieure droite du graphique sont généralement les plus performantes.

6.3 Dashboard 3 : Match Analysis

Ce tableau de bord propose une analyse détaillée des matchs et de leurs caractéristiques.

KPIs

- **Average Goals per Match** : moyenne de buts marqués par match.
- **Highest Scoring Match** : match avec le plus grand nombre total de buts.
- **Biggest Win** : match avec la plus grande différence de buts.

Visualisations

- **High Scoring Matches (Table)** Liste les matchs avec un nombre élevé de buts, permettant d'identifier les rencontres les plus spectaculaires.
- **Score Heatmap** Représente la distribution des scores (buts domicile vs buts extérieur). Cette visualisation permet d'identifier les scores les plus fréquents.
- **Total Goals by Country (Map)** Affiche la distribution géographique du nombre total de buts selon les pays des équipes. Ce graphique permet d'identifier les régions où les matchs sont généralement plus offensifs.

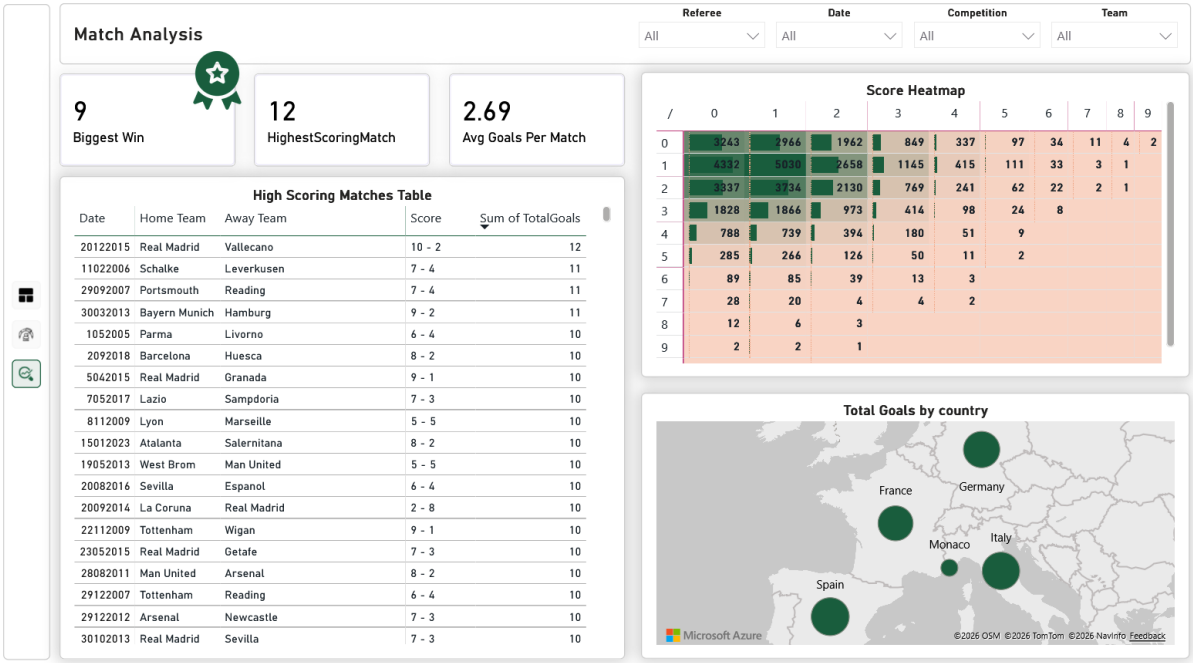

FIGURE 12 – Dashboard Match Analysis

Ces tableaux de bord permettent d'explorer efficacement les données du football sous différents angles analytiques. Grâce à l'utilisation de filtres interactifs, les utilisateurs peuvent facilement analyser les performances des équipes, comparer les compétitions et identifier des tendances dans les résultats des matchs.

7 Conclusion

Ce projet avait pour objectif de concevoir un système décisionnel permettant d'analyser les résultats des matchs de football à partir de données historiques provenant des principales ligues européennes. Pour atteindre cet objectif, nous avons mis en place une architecture complète allant de la collecte des données jusqu'à la visualisation analytique.

Dans un premier temps, les données ont été collectées à partir de sources publiques et préparées afin de garantir leur qualité et leur cohérence. Ces données ont ensuite été intégrées dans un **entrepôt de données** conçu selon un modèle multidimensionnel de type **schéma en étoile**. Cette modélisation a permis d'organiser efficacement les informations autour d'une table de faits centrale décrivant les matchs, accompagnée de plusieurs dimensions permettant l'analyse selon différents axes tels que les équipes, les compétitions, les dates ou les arbitres.

Le processus d'intégration des données a été réalisé à l'aide d'un pipeline **ETL implémenté avec Talend**. Ce processus a permis d'extraire les données brutes, d'effectuer les transformations nécessaires (nettoyage, création des clés dimensionnelles) puis de charger les données dans l'entrepôt PostgreSQL.

Enfin, les données ont été exploitées à travers la création de **tableaux de bord interactifs avec Power BI**. Ces tableaux de bord permettent d'explorer les données de manière dynamique grâce à différents filtres et visualisations. Ils offrent notamment la possibilité d'analyser les performances des équipes, la distribution des résultats des matchs, les tendances de scoring ainsi que les différences entre compétitions.

Les résultats obtenus montrent que l'utilisation d'un système décisionnel facilite considérablement l'analyse de grandes quantités de données sportives. Les visualisations interactives permettent d'identifier rapidement des tendances, telles que l'avantage du terrain, les différences de performances entre équipes ou encore les variations du nombre de buts au fil du temps.

Cependant, certaines limites peuvent être mentionnées. Les données utilisées se concentrent principalement sur les résultats des matchs et n'incluent pas d'autres statistiques avancées telles que les tirs, la possession de balle ou les expected goals. L'intégration de ces informations pourrait permettre d'obtenir des analyses plus approfondies.

Dans une perspective future, plusieurs améliorations pourraient être envisagées, notamment l'intégration de nouvelles sources de données, l'automatisation complète du processus de collecte des données ou encore l'ajout de modèles d'analyse prédictive afin d'anticiper les résultats des matchs.

Ainsi, ce projet illustre l'intérêt des technologies de **Big Data et de Business Intelligence** dans l'analyse des données sportives et démontre comment un entrepôt de données associé à des outils de visualisation peut fournir un support efficace pour l'aide à la décision.