Projet Big Data

Master 2 SID

Analyse des Matchs de Football des 5 Grandes Ligues Européennes

Rédigé le 15/03/2026, par

TIOUAL Ahmed
EL MAATLA Lotfi

Encadré par

Prof. MINICH Sarah

Table des matières

1 Introduction **2**

2 Sources de données **2**

2.1 Périmètre de l'étude 2

2.2 Collecte et Format 3

2.3 Description des attributs 3

3 Modélisation multidimensionnelle **3**

3.1 Schéma en étoile 3

3.2 Table de faits 4

3.3 Tables de dimensions 5

3.3.1 Dimension Équipe 5

3.3.2 Dimension Compétition 5

3.3.3 Dimension Date 5

3.3.4 Dimension Arbitre 6

3.4 Avantages du modèle 6

4 Processus ETL **6**

4.1 Extraction des données 6

4.2 Transformation des données 7

4.3 Chargement dans l'entrepôt de données 7

4.4 Flux ETL dans Talend 7

5 Entrepôt de données **9**

5.1 Structure de l'entrepôt 9

5.2 Table de faits 10

5.3 Tables de dimensions 11

5.4 Avantages de l'entrepôt de données 12

6 Visualisation et tableaux de bord **13**

6.1 Dashboard 1 : League Overview 13

6.2 Dashboard 2 : Team Performance 14

6.3 Dashboard 3 : Match Analysis 15

7 Conclusion **16**

1 Introduction

L'analyse des données sportives est devenue un levier stratégique dans le football moderne. Les clubs et les analystes exploitent désormais ces informations pour décrypter les performances, anticiper les résultats et identifier des tendances structurelles sur le long terme.

Dans le cadre du module **Big Data**, l'objectif est de concevoir un système décisionnel complet permettant d'explorer les résultats des principales ligues européennes sur une période de 24 ans (**2000 à 2024**). Ce projet vise à transformer des données historiques brutes en indicateurs visuels pertinents pour l'analyse sportive.

Afin de répondre à ces enjeux, nous avons structuré notre démarche autour d'une architecture décisionnelle classique :

- **Collecte et ingestion** : Récupération automatisée des données sources.
- **Modélisation** : Conception d'un schéma multidimensionnel (étoile) adapté au décisionnel.
- **Intégration (ETL)** : Nettoyage et chargement des données via Talend vers PostgreSQL.
- **Restitution** : Création de tableaux de bord interactifs sous Power BI.

Ce rapport détaille chaque étape de cette chaîne de valeur, des choix techniques de stockage jusqu'aux analyses finales.

2 Sources de données

La fiabilité du système décisionnel repose sur la qualité des sources primaires. Pour ce projet, les données ont été extraites du site *football-data.co.uk*, une référence publique pour les statistiques historiques du football européen.

2.1 Périmètre de l'étude

Le jeu de données agrège les résultats des cinq championnats majeurs, offrant ainsi une vision comparative des dynamiques européennes :

- **Angleterre** (Premier League), **Espagne** (La Liga), **Italie** (Serie A), **Allemagne** (Bundesliga) et **France** (Ligue 1).

2.2 Collecte et Format

Les données sont initialement fournies sous forme de fichiers **CSV** par saison. Nous avons mis en place un processus de **scraping** permettant l'automatisation du téléchargement de ces fichiers. Ce mode opératoire garantit la reproductibilité de la collecte pour les saisons futures.

2.3 Description des attributs

Chaque enregistrement représente un match unique. Les fichiers bruts contiennent des informations cruciales qui servent de base à nos indicateurs :

- **Informations temporelles** : Date précise de la rencontre.
- **Acteurs** : Équipes (domicile/extérieur) et arbitre désigné.
- **Scores** : Résultats à la mi-temps et score final.
- **Résultat technique** : Issue du match (Victoire domicile, Nul, Victoire extérieur).

Ces données brutes subissent ensuite une phase de prétraitement pour corriger les éventuelles incohérences avant d'alimenter l'entrepôt de données.

3 Modélisation multidimensionnelle

Afin de faciliter l'analyse décisionnelle des données de matchs de football, nous avons adopté une approche de modélisation multidimensionnelle basée sur un **schéma en étoile (Star Schema)**. Ce type de modélisation est largement utilisé dans les entrepôts de données car il permet d'optimiser les requêtes analytiques et de simplifier l'exploration des données.

Le schéma en étoile se compose d'une **table de faits centrale** contenant les mesures quantitatives, entourée de plusieurs **tables de dimensions** décrivant le contexte des observations.

3.1 Schéma en étoile

La Figure 1 présente la structure du modèle multidimensionnel utilisé dans ce projet.
Dans ce modèle, la table de faits *Fact_Match* est reliée à plusieurs dimensions permettant d'analyser les données selon différents axes tels que les équipes, la compétition, la date ou l'arbitre.

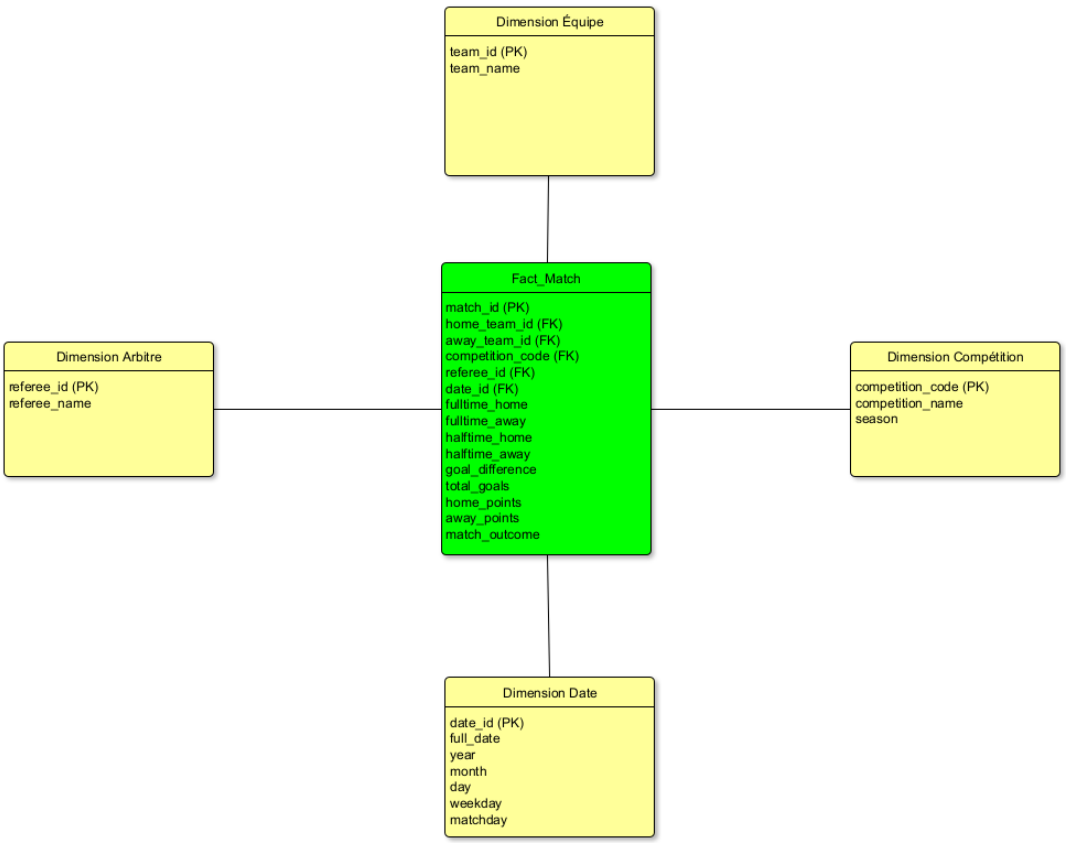

FIGURE 1 – Schéma en étoile de l'entrepôt de données des matchs de football

3.2 Table de faits

La table de faits **Fact_Match** contient les mesures principales associées à chaque match. Chaque enregistrement représente une rencontre entre deux équipes dans une compétition donnée.

Les principales mesures stockées dans cette table sont :

- le nombre de buts marqués par l'équipe à domicile (*fulltime_home*) ;
- le nombre de buts marqués par l'équipe à l'extérieur (*fulltime_away*) ;
- le nombre total de buts du match (*total_goals*) ;
- la différence de buts (*goal_difference*) ;
- les points attribués aux équipes (*home_points* et *away_points*) ;
- le résultat final du match (*match_outcome*).

Cette table contient également plusieurs clés étrangères permettant de relier les mesures aux différentes dimensions analytiques.

3.3 Tables de dimensions

Plusieurs tables de dimensions ont été créées afin de fournir le contexte nécessaire à l'analyse des matchs.

3.3.1 Dimension Équipe

La dimension **Dim_Team** contient les informations relatives aux équipes participant aux différentes compétitions.

- **team_id** : identifiant unique de l'équipe
- **team_name** : nom de l'équipe
- **city** : ville du club
- **country** : pays du club

Cette dimension est utilisée deux fois dans la table de faits pour représenter l'équipe à domicile et l'équipe à l'extérieur.

3.3.2 Dimension Compétition

La dimension **Dim_Competition** décrit les différentes compétitions étudiées dans le projet.

- **competition_code** : identifiant de la compétition
- **competition_name** : nom de la compétition
- **season** : saison sportive

Cette dimension permet d'analyser les performances par championnat et par saison.

3.3.3 Dimension Date

La dimension **Dim_Date** permet d'effectuer des analyses temporelles.

- **date_id** : identifiant de la date
- **full_date** : date complète du match
- **year** : année
- **month** : mois
- **day** : jour
- **weekday** : jour de la semaine

Grâce à cette dimension, il est possible d'étudier l'évolution des performances et du nombre de buts au fil du temps.

3.3.4 Dimension Arbitre

La dimension **Dim_Referee** contient les informations sur les arbitres ayant officié les matchs.

- **referee_id** : identifiant de l'arbitre
- **referee_name** : nom de l'arbitre

Cette dimension permet notamment d'analyser le nombre de matchs arbitrés ainsi que certaines tendances liées aux rencontres dirigées par différents arbitres.

3.4 Avantages du modèle

Ce modèle multidimensionnel permet d'analyser les matchs de football selon plusieurs perspectives :

- l'évolution des buts marqués au cours du temps ;
- la performance des équipes dans différentes compétitions ;
- la comparaison entre les matchs à domicile et à l'extérieur ;
- l'analyse des statistiques par arbitre ou par championnat.

Il constitue ainsi une base solide pour l'intégration des données dans l'entrepôt de données et pour la création des tableaux de bord analytiques présentés dans la suite du rapport.

4 Processus ETL

Afin d'intégrer les données collectées dans l'entrepôt de données, nous avons mis en place un processus **ETL (Extract, Transform, Load)**. Ce processus permet d'extraire les données brutes, de les transformer afin d'assurer leur cohérence et leur qualité, puis de les charger dans la structure multidimensionnelle définie précédemment.

Pour implémenter ce pipeline de données, nous avons utilisé l'outil **Talend Open Studio**, qui permet d'automatiser les flux et de gérer efficacement l'intégration vers notre base PostgreSQL.

4.1 Extraction des données

Contrairement à une approche par fichiers séparés, la première étape du processus repose sur l'exploitation d'un **fichier CSV unique**, généré lors de la phase de scraping. Ce fichier consolide l'ensemble des matchs de toutes les ligues et saisons étudiées (2000-2024).

L'importation dans Talend s'effectue via le composant `tFileInputDelimited`. Ce fichier source contient toutes les informations nécessaires à l'alimentation du modèle, notamment :

- la date du match ;
- les équipes à domicile et à l'extérieur ;
- les scores à la mi-temps et à la fin du match ;
- l'arbitre du match ;
- le résultat final de la rencontre.

L'utilisation d'un fichier consolidé dès l'extraction simplifie le pipeline Talend en évitant l'usage de boucles complexes d'itération sur plusieurs répertoires.

4.2 Transformation des données

Après l'extraction, les données subissent une série de transformations visant à garantir leur intégrité et leur adéquation avec le modèle multidimensionnel cible.

L'implémentation de cette logique repose sur l'utilisation combinée de trois composants clés dans Talend :

- **Conversion et typage (`tConvertType`)** : Conversion des types (scores en entiers, dates en format *Date*) afin d'assurer la compatibilité avec PostgreSQL.
- **Gestion de l'unicité (`tUniqRow`)** : Élimination des doublons pour garantir l'unicité des dimensions et préserver l'intégrité référentielle.
- **Logique métier et mapping (`tMap`)** : Composant central regroupant :
  - **Standardisation** : Uniformisation des noms et codes.
  - **Règles de gestion** : Calcul des points (3/1/0).
  - **Jointures (Lookups)** : Récupération des clés étrangères.

Ces composants permettent d'obtenir un flux de données propre, typé et structuré avant son insertion finale.

4.3 Chargement dans l'entrepôt de données

La dernière étape consiste à charger les données dans **PostgreSQL** selon une logique de schéma en étoile.

- Chargement des tables de dimensions (*Dim_ Team*, *Dim_ Competition*, etc.).
- Insertion dans la table de faits (*Fact_ Match*) après récupération des clés étrangères.

4.4 Flux ETL dans Talend

L'implémentation a été structurée en deux jobs principaux orchestrés par un job maître.

1. Alimentation des dimensions

La Figure 2 illustre l'extraction des valeurs distinctes via `tUniqRow` pour alimenter les dimensions.

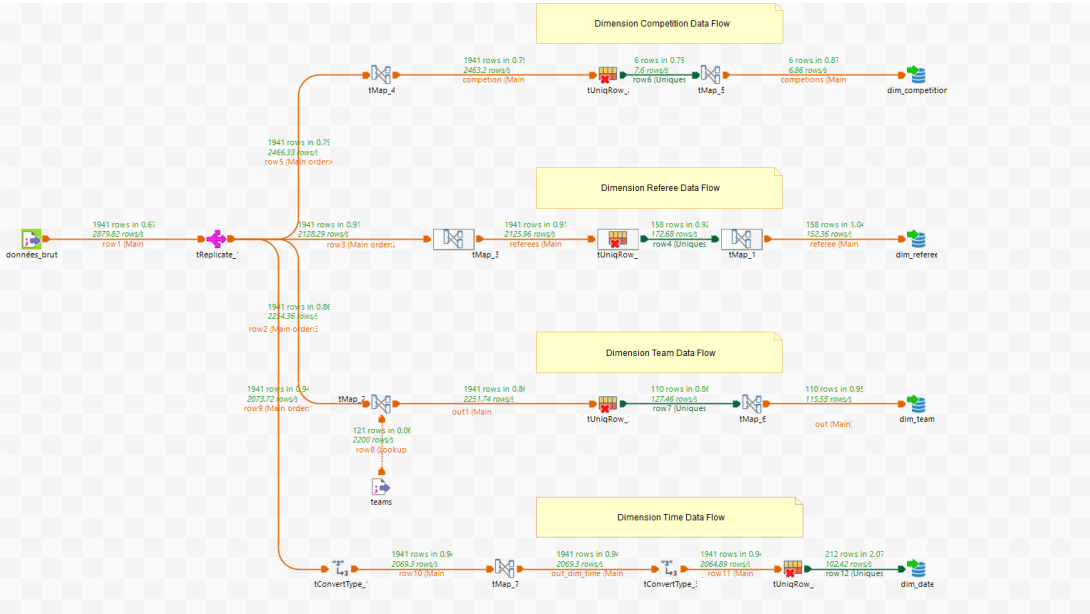

FIGURE 2 – Flux ETL d'alimentation des dimensions (DIM_JOB)

2. Alimentation de la table de faits

Une fois les dimensions chargées, le flux de la table de faits (Figure 3) réalise les jointures via `tMap` afin de récupérer les clés étrangères avant insertion.

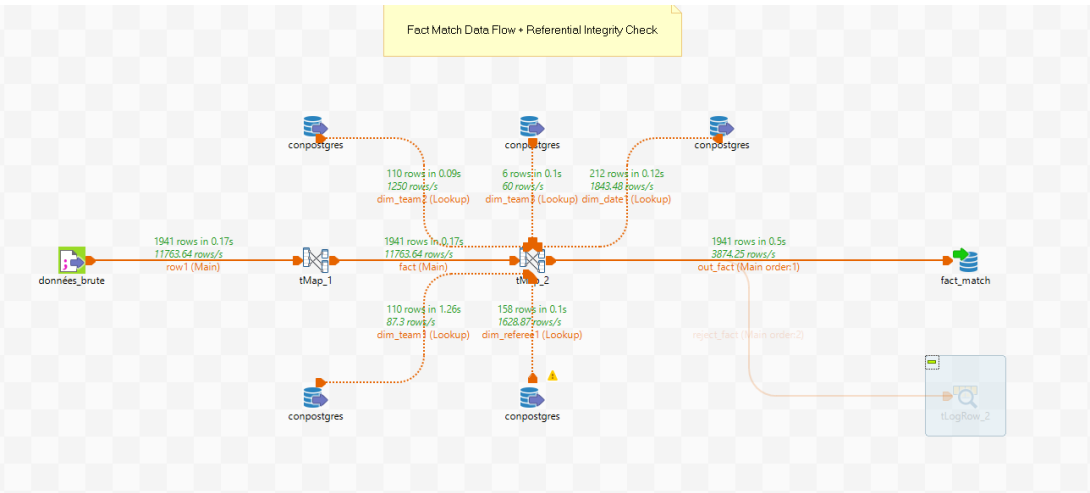

FIGURE 3 – Flux ETL d'alimentation de la table de faits (FACT_JOB)

3. Orchestration globale (Job Maître)

Le job maître (Figure 4) garantit que les dimensions sont chargées avant les faits.

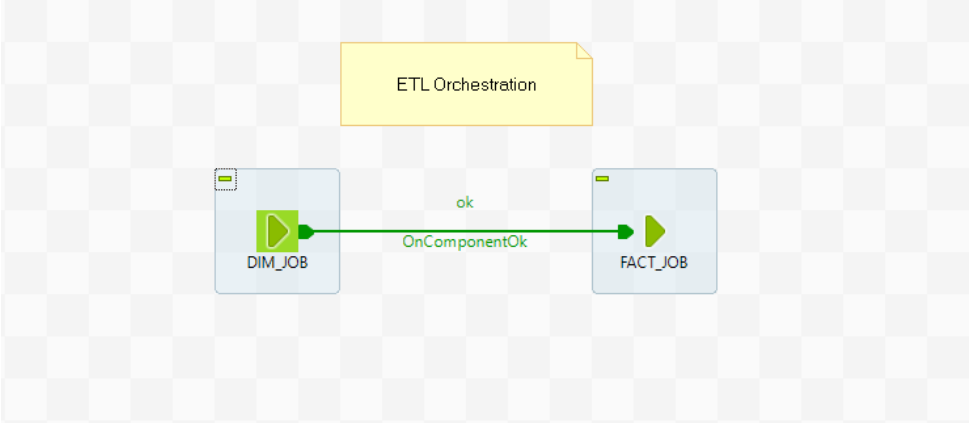

FIGURE 4 – Orchestration des flux : DIM_JOB suivi de FACT_JOB

5 Entrepôt de données

Après la phase de modélisation multidimensionnelle et la mise en place du processus ETL, les données transformées ont été stockées dans un **entrepôt de données** afin de permettre leur exploitation analytique.

L'entrepôt de données constitue la base centrale du système décisionnel et permet de consolider l'ensemble des informations issues des différentes sources.

Dans ce projet, l'entrepôt de données a été implémenté à l'aide du système de gestion de base de données relationnelle **PostgreSQL**. Ce choix repose sur sa robustesse, sa capacité à gérer de grands volumes de données et sa compatibilité avec les outils utilisés.

5.1 Structure de l'entrepôt

L'entrepôt de données est structuré selon un modèle multidimensionnel de type **schéma en étoile**.

L'entrepôt est composé des tables suivantes :

- **Fact_Match** : table de faits contenant les mesures principales associées aux matchs.
- **Dim_Team** : dimension contenant les informations sur les équipes.
- **Dim_Competition** : dimension décrivant les compétitions et les saisons.
- **Dim_Date** : dimension temporelle permettant les analyses par date.

- **Dim_Referee** : dimension contenant les informations sur les arbitres.

Chaque table de dimension possède une clé primaire utilisée comme clé de substitution dans la table de faits *Fact_Match*, permettant de relier efficacement les mesures aux axes d'analyse.

5.2 Table de faits

La table **Fact_Match** représente le cœur de l'entrepôt de données. Chaque enregistrement correspond à un match.

Cette table contient notamment les attributs suivants :

- **home_team_id** et **away_team_id**
- **competition_code**
- **referee_id**
- **date_id**
- **fulltime_home** et **fulltime_away**
- **total_goals**
- **goal_difference**
- **home_points** et **away_points**
- **match_outcome**

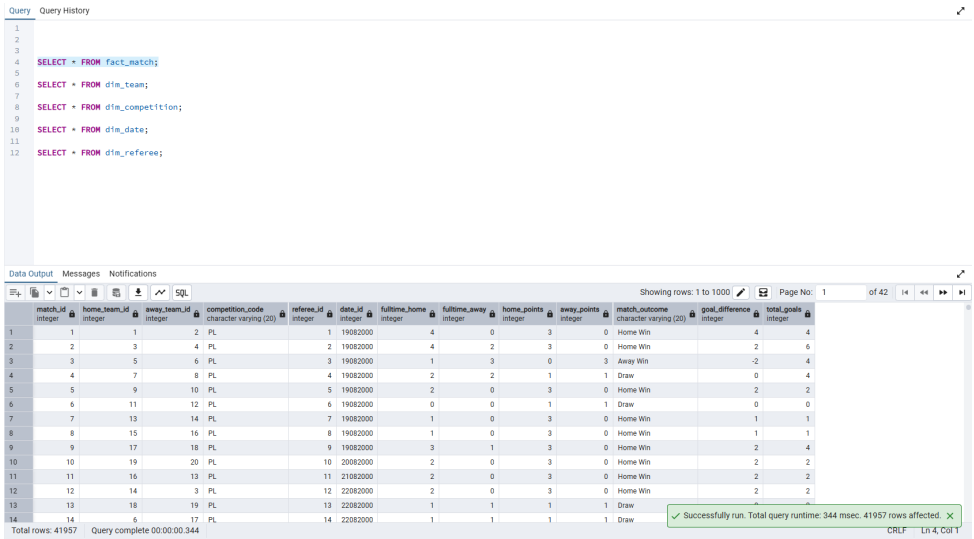

FIGURE 5 – Capture des données de la table Fact_Match

Ces mesures permettent de construire différents indicateurs analytiques liés aux performances et aux résultats.

5.3 Tables de dimensions

Les tables de dimensions apportent le contexte nécessaire à l'analyse des données.

Dim_Team contient les informations sur les équipes (nom, ville, pays).

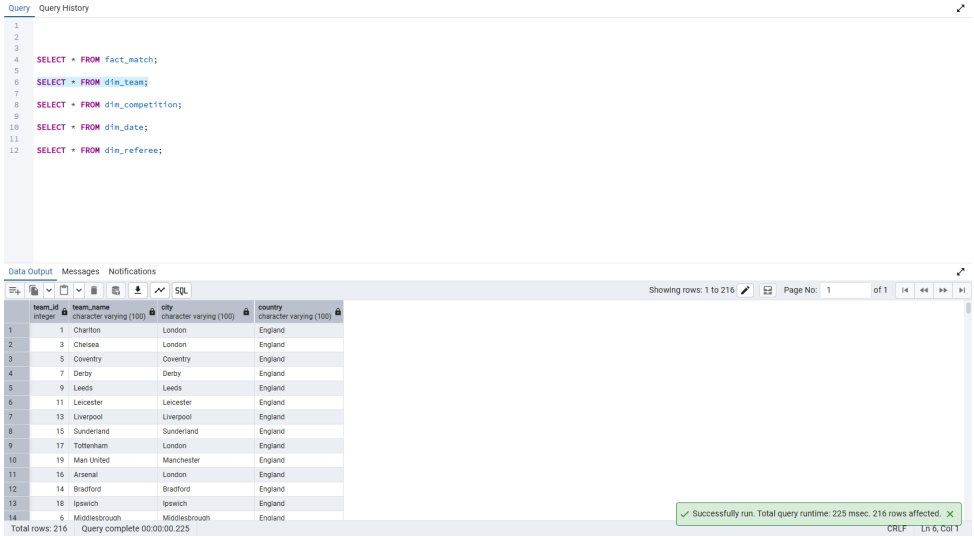

FIGURE 6 – Capture des données de la table Dim_Team

Dim_Competition regroupe les informations relatives aux compétitions et aux saisons.

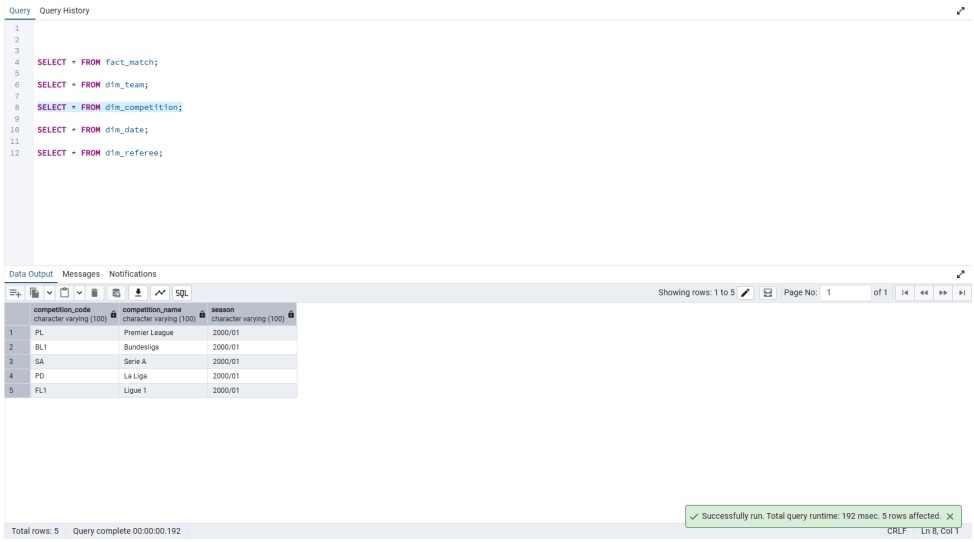

FIGURE 7 – Capture des données de la table Dim_Competition

Dim_Date fournit les informations temporelles nécessaires aux analyses chronologiques.

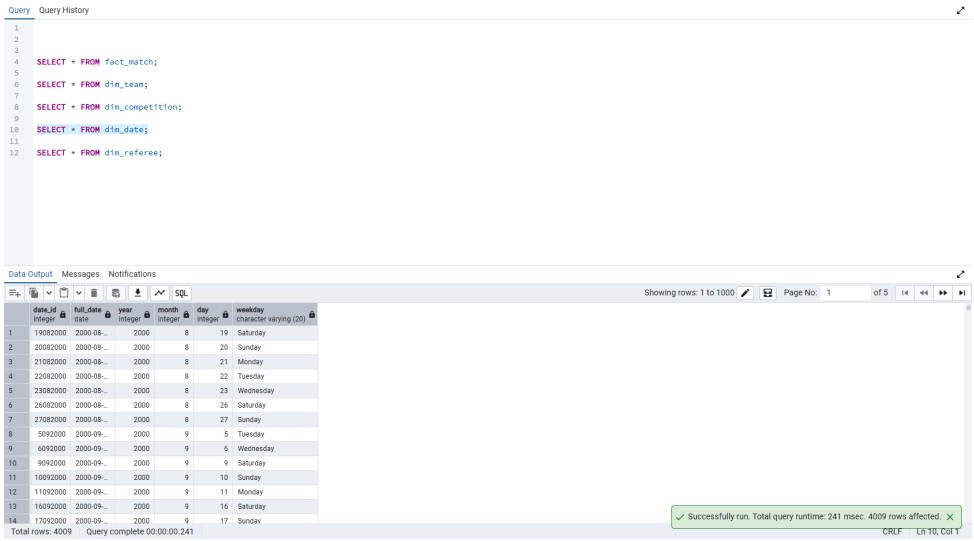

```
SELECT * FROM fact_match;

SELECT * FROM dim_team;

SELECT * FROM dim_competition;

SELECT * FROM dim_date;

SELECT * FROM dim_referee;
```

	date_id integer	full_date date	year integer	month integer	day integer	weekday character varying (20)
1	19082000	2000-08-...	2000	8	19	Saturday
2	20082000	2000-08-...	2000	8	20	Sunday
3	21082000	2000-08-...	2000	8	21	Monday
4	22082000	2000-08-...	2000	8	22	Tuesday
5	23082000	2000-08-...	2000	8	23	Wednesday
6	26082000	2000-08-...	2000	8	26	Saturday
7	27082000	2000-08-...	2000	8	27	Sunday
8	5092000	2000-09-...	2000	9	5	Tuesday
9	6092000	2000-09-...	2000	9	6	Wednesday
10	9092000	2000-09-...	2000	9	9	Saturday
11	10092000	2000-09-...	2000	9	10	Sunday
12	11092000	2000-09-...	2000	9	11	Monday
13	16092000	2000-09-...	2000	9	16	Saturday
14	17092000	2000-09-...	2000	9	17	Sunday

Total rows: 4009 Query complete 00:00:00.241

Figure 8 – Capture des données de la table Dim_Date

Dim_Referee contient les informations sur les arbitres.

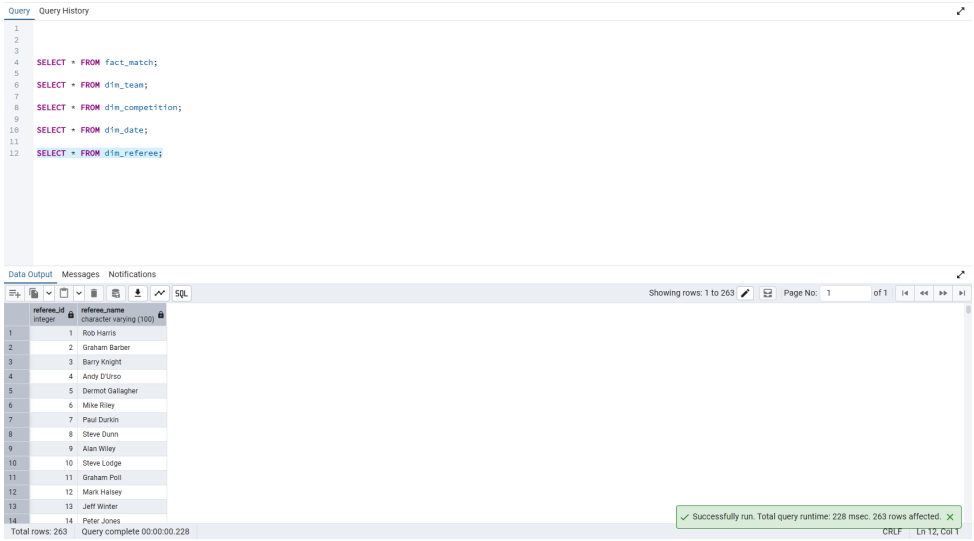

```
SELECT * FROM fact_match;

SELECT * FROM dim_team;

SELECT * FROM dim_competition;

SELECT * FROM dim_date;

SELECT * FROM dim_referee;
```

	referee_id integer	referee_name character varying (100)
1	1	Rob Harris
2	2	Graham Barber
3	3	Barry Knight
4	4	Andy D'Urso
5	5	Dermot Gallagher
6	6	Mike Riley
7	7	Paul Durkin
8	8	Steve Dunn
9	9	Alan Wiley
10	10	Steve Lodge
11	11	Graham Poll
12	12	Mark Halsey
13	13	Jeff Winter
14	14	Peter Jones

Total rows: 263 Query complete 00:00:00.228

Figure 9 – Capture des données de la table Dim_Referee

5.4 Avantages de l'entrepôt de données

La mise en place de cet entrepôt de données présente plusieurs avantages :

- centralisation des données ;
- amélioration des performances analytiques ;
- simplification du reporting ;
- analyse multidimensionnelle (temps, équipe, compétition, arbitre).

Cet entrepôt constitue la base d'alimentation des tableaux de bord Power BI présentés dans la suite du rapport.

6 Visualisation et tableaux de bord

Après l'intégration des données dans l'entrepôt de données, l'étape suivante consiste à exploiter ces informations afin de produire des analyses visuelles.

Pour cela, nous avons utilisé l'outil **Power BI**, qui permet de créer des tableaux de bord interactifs facilitant l'exploration et l'analyse des données.

Les tableaux de bord développés permettent d'analyser les performances des équipes, les résultats des matchs ainsi que les tendances globales des compétitions.

Afin d'améliorer l'interactivité, plusieurs **filtres (slicers)** ont été intégrés :

- Compétition
- Équipe
- Date
- Arbitre

Ces filtres permettent d'explorer dynamiquement les données selon différents critères.

6.1 Dashboard 1 : League Overview

Ce tableau de bord offre une vue globale des compétitions et des performances générales.

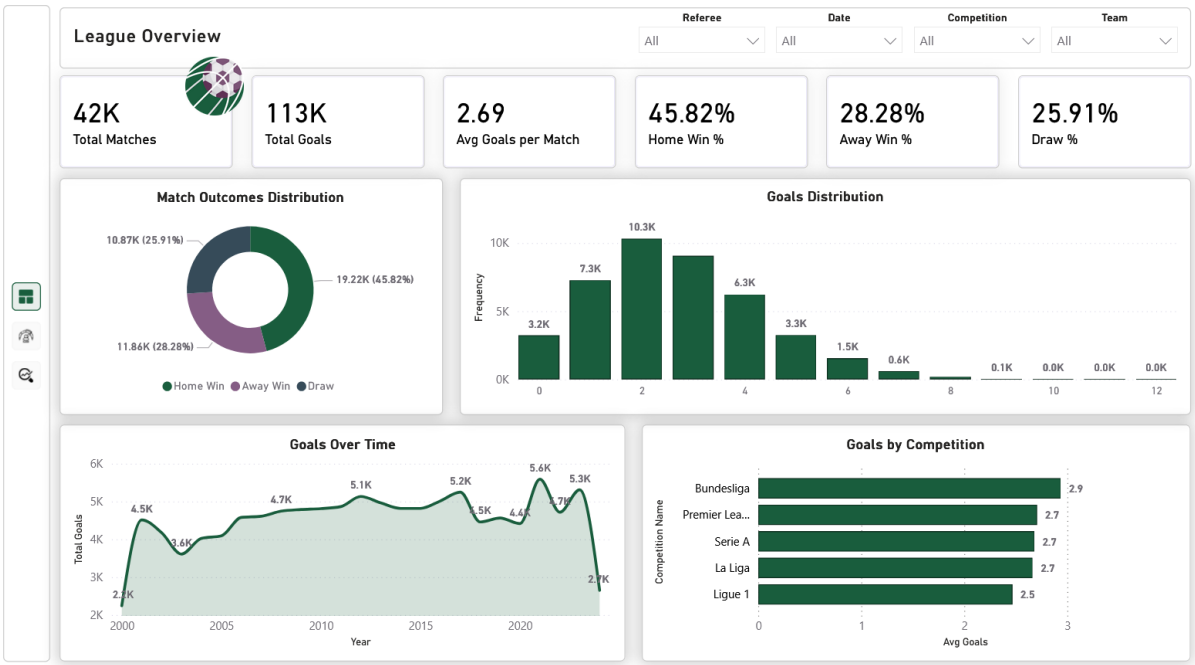

FIGURE 10 – Dashboard League Overview

KPIs

- **Total Matches**

- **Total Goals**
- **Average Goals per Match**
- **Home Win %**
- **Away Win %**
- **Draw %**

Visualisations

- **Match Outcomes Distribution (Pie Chart)** Répartition des résultats des matchs.
- **Goals Distribution (Histogram)** Distribution du nombre de buts par match.
- **Goals Over Time (Line Chart)** Évolution des buts dans le temps.
- **Goals by Competition (Bar Chart)** Comparaison des compétitions.

6.2 Dashboard 2 : Team Performance

Ce tableau de bord analyse les performances des équipes.

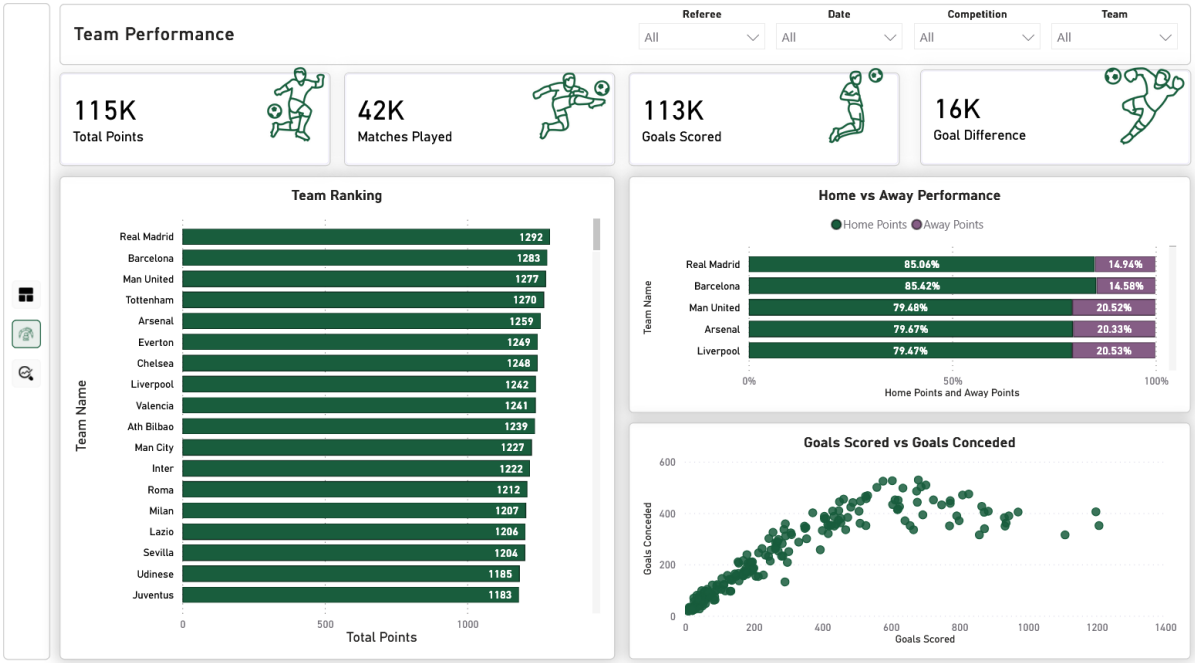

FIGURE 11 – Dashboard Team Performance

KPIs

- **Total Points**
- **Matches Played**
- **Goals Scored**
- **Goal Difference**

Visualisations

- **Team Ranking (Bar Chart)** Classement des équipes.
- **Home vs Away Performance (Stacked Bar Chart)** Comparaison domicile/extérieur.
- **Goals Scored vs Goals Conceded (Scatter Plot)** Analyse offensive/défensive.

6.3 Dashboard 3 : Match Analysis

Ce tableau de bord propose une analyse détaillée des matchs.

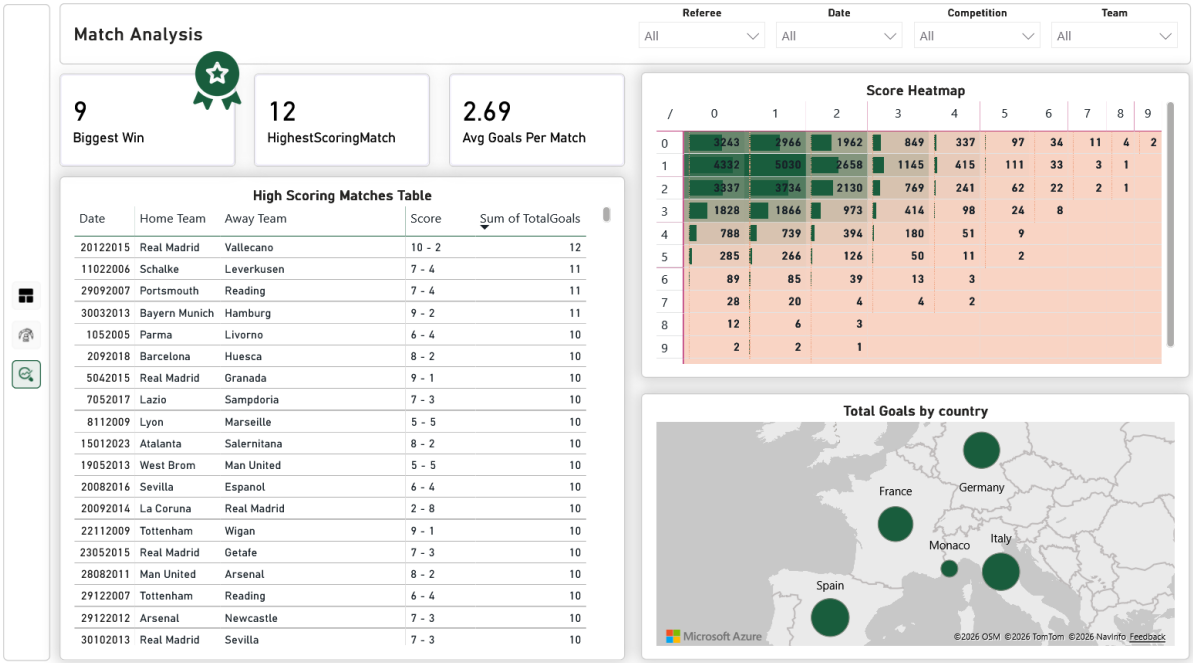

FIGURE 12 – Dashboard Match Analysis

KPIs

- **Average Goals per Match**
- **Highest Scoring Match**
- **Biggest Win**

Visualisations

- **High Scoring Matches (Table)** Liste des matchs à fort score.
- **Score Heatmap** Distribution des scores.
- **Total Goals by Country (Map)** Répartition géographique des buts.

Ces tableaux de bord permettent d'explorer efficacement les données sous différents angles analytiques grâce à l'interactivité des filtres.

7 Conclusion

Ce projet avait pour objectif de concevoir un système décisionnel permettant d'analyser les résultats des matchs de football à partir de données historiques provenant des principales ligues européennes.

Pour atteindre cet objectif, nous avons mis en place une architecture complète allant de la collecte des données jusqu'à la visualisation analytique.

Dans un premier temps, les données ont été collectées à partir de sources publiques et préparées afin de garantir leur qualité et leur cohérence. Elles ont ensuite été intégrées dans un **entrepôt de données** conçu selon un modèle multidimensionnel de type **schéma en étoile**.

Cette modélisation a permis d'organiser efficacement les informations autour d'une table de faits centrale décrivant les matchs, accompagnée de plusieurs dimensions (équipes, compétitions, dates, arbitres).

Le processus d'intégration a été réalisé via un pipeline **ETL implémenté avec Talend**, permettant l'extraction, la transformation (nettoyage, création des clés) et le chargement dans **PostgreSQL**.

Enfin, les données ont été exploitées à travers des **tableaux de bord interactifs sous Power BI**, offrant une exploration dynamique via des filtres et visualisations.

Les analyses permettent notamment d'identifier des tendances telles que l'avantage du terrain, les différences de performances entre équipes et les variations du nombre de buts dans le temps.

Cependant, certaines limites doivent être soulignées. Les données utilisées restent limitées aux résultats des matchs et n'intègrent pas de statistiques avancées (tirs, possession, expected goals), ce qui réduit la profondeur analytique.

Des améliorations sont envisageables :

- intégration de nouvelles sources de données ;
- automatisation complète du pipeline ;
- ajout de modèles prédictifs.

Ce projet met en évidence l'intérêt des approches **Big Data** et **Business Intelligence** pour transformer des données brutes en informations exploitables pour l'aide à la décision.